



1. Entraînement

Le modèle apprend à générer du texte.

Beaucoup d'énergie consommé pendant plusieurs semaines, mais fait qu'une seule fois par modèle.

2. Utilisation (inférence)

Le modèle génère du texte à partir d'un prompt.

Peu d'énergie consommée par demande, mais si beaucoup de demande, la consommation cumulée devient considérable.





1. Entraînement

Le modèle apprend à générer du texte.

Beaucoup d'énergie consommé pendant plusieurs semaines, mais fait qu'une seule fois par modèle.

Exemple de consommation d'entraînement



= 21 000 GWh consommés pour l'entraînement

= 10 000 ménages pendant un an

source : Données de Meta sur LLama 4



2. Utilisation (inférence)

Le modèle génère du texte à partir d'un prompt.

Peu d'énergie consommée par demande, mais si beaucoup de demande, la consommation cumulée devient considérable.

Exemple de consommation d'inférence :



OpenAI/GPT 4o

Méthodologie : Ecologits

= 14.9 Wh consommés pour écrire un mail (170 jetons) = 1 smartphone rechargé





2. Utilisation (inférence)

Le modèle génère du texte à partir d'un prompt.

Peu d'énergie consommée par demande, mais si beaucoup de demande, la consommation cumulée devient considérable.

Exemple de consommation d'inférence :



OpenAI/GPT 4o

Méthodologie : Ecologits

= 14.9 Wh

consommés pour écrire un mail (170 jetons) = 1 smartphone

rechargé

Si 1% de la population mondiale le faisait tous les jours pendant un an, ce serait équivalent à 💢 1,502 vols Paris 🖾 NYC en termes d'émissions.





2. Utilisation (inférence)

Le modèle génère du texte à partir d'un prompt.

Peu d'énergie consommée par demande, mais si beaucoup de demande, la consommation cumulée devient considérable.



Question posée sur X (Twitter)
« Combien d'argent OpenAI [les créateurs de ChatGPT] perd à cause des gens qui disent "s'il te plaît" et "merci" à leurs modèles ? »

Réponse de Sam Altman, PDG d'OpenAl « Des dizaines de millions de dollars [...] »