La consommation d’un modèle

Pour chaque requête, la consommation d’IA en ressources dépend de ces trois principaux facteurs :

Taille du modèle

En milliards de paramètres

Longueur du texte

En jetons

Architecture

Par exemple MoE ou MatFormer

Taille du modèle - facteurs de consommation

Qu'est-ce que la "taille" d'un modèle ?

Les duels de l'IA
par compar:IA

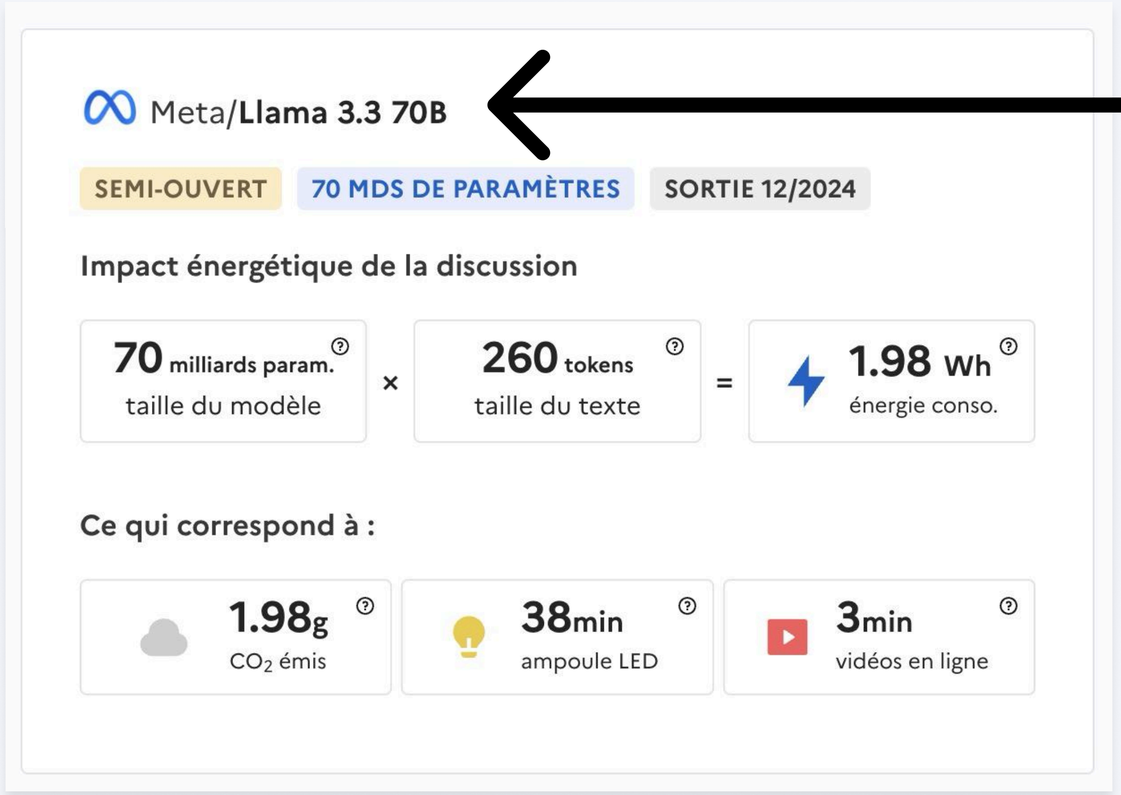

Quantité de paramètres

70B = 70 milliards de paramètres

Meta/**Llama 3.3 70B**

Un paramètre est comme une "synapse" artificiel. Plus il y a de paramètres, plus (en théorie) un modèle a de capacité d'apprendre. Néanmoins, ça ne veut pas dire qu'un modèle plus grand sera toujours plus "intelligent".

Taille du modèle - facteurs de consommation

Qu'est-ce que la "taille" d'un modèle ?

Les duels de l'IA
par compar:IA

Anthropic/**Claude 3.5 Sonnet**	→	**300** milliards de paramètres (env)	→ **XL**
Meta/**Llama 3.3 70B**	→	**70** milliards de paramètres	→ **L**
Mistral/**Mistral Small**	→	**24** milliards de paramètres	→ **M**
Google/**Gemma 3 4b**	→	**4** milliards de paramètres	→ **XS**

Taille du modèle - facteurs de consommation

Influence de la "taille"

Les duels de l'IA
par compar:IA

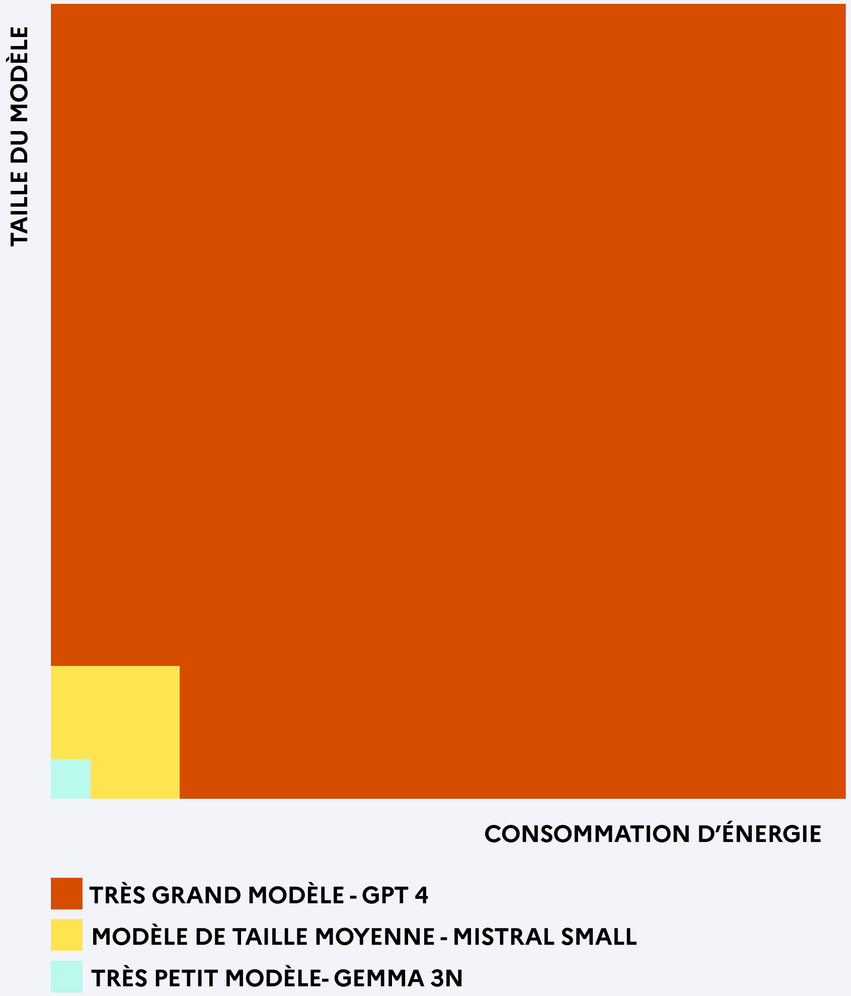

Un paramètre est comme une "synapse" artificiel. Plus il y a de paramètres, plus (en théorie) un modèle a de capacité d'apprendre. Néanmoins, ça ne veut pas dire qu'un modèle plus grand sera toujours plus "intelligent".

Par contre, **la taille a une grande influence sur la puissance de calcul nécessaire pour faire fonctionner le modèle et donc sur la consommation énergétique.**

Graphique - Conseil National du Numérique :
"20 cartes pour aborder l'impact énergétique de l'IA générative"

conseil national du numérique

Longueur du texte - facteurs de consommation

Les “jetons”

Les duels de l’IA
par compar:IA

La longueur du texte produit par un modèle de langage se quantifie en "jetons" (tokens).

Un jeton constitue une unité de base qui peut englober un ou plusieurs caractères, selon leur fréquence d'apparition ensemble dans la langue.

Par exemple :

Salut

1 JETON

Salut, ça va ?

5 JETONS

La jetonisation sert à :

- Découper le texte en morceaux que l'IA peut comprendre
- Compter combien de "mots" l'IA peut traiter d'un coup
- Calculer le coût d'utilisation du modèle

Architectures - facteurs de consommation

Les “mélanges d’experts”

Les duels de l’IA
par compar:IA

Les modèles “mélanges d’experts” (Mixture of Experts) contiennent plusieurs experts, mais un seul est activé à chaque jeton.

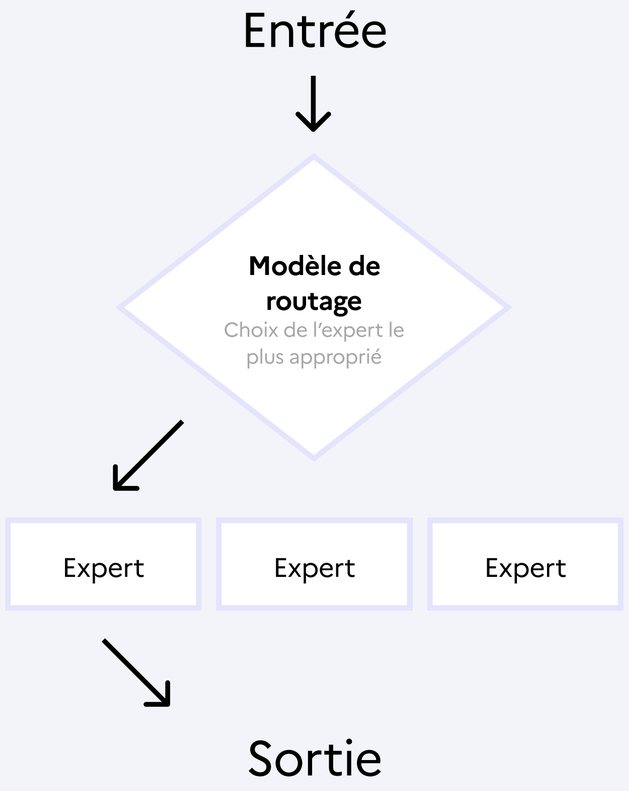

Avantages

- Moins de puissance de calcul nécessaire
  - DONC consomme moins d’électricité
  - DONC coûte moins cher à utiliser

Désavantages

- Prend beaucoup de place dans la mémoire de la machine
- Plus complexe à développer
- Peut avoir des problèmes de généralisation

Exemples

Mistral/**Mistral 8x7B**

DeepSeek/**DeepSeek V3**

Meta/**Llama 4 Scout**