

# La consommation d'un modèle



**Les duels de l'IA**  
par compar:IA

Pour chaque requête, la consommation d'IA en ressources dépend de ces trois principaux facteurs :

**Taille du modèle**



*En milliards de  
paramètres*


**Longueur du texte**

*En jetons*

**Architecture**

*Par exemple MoE ou  
MatFormer*






Taille du modèle - facteurs de consommation


# Qu'est-ce que la "taille" d'un modèle ?

## Quantité de paramètres

4B = 4 milliards de paramètres


Un paramètre d'un modèle d'IA est un nombre appris pendant l'entraînement qui règle comment le modèle transforme une entrée en sortie.





Taille du modèle - facteurs de consommation

# Qu'est-ce que la "taille" d'un modèle ?




Anthropic/Claude 4.5 Sonnet

→ **300** milliards de **paramètres** (env) → **XL**



Meta/Llama 3.3 70B

→ **70** milliards de **paramètres** → **L**



Mistral/Mistral Small


→ **24** milliards de **paramètres** → **M**



Google/Gemma 3 4b


→ **4** milliards de **paramètres** → **XS**





# Taille du modèle - facteurs de consommation

## Influence de la "taille"




Un paramètre est comme une "synapse" artificielle. Plus il y a de paramètres, plus (en théorie) un modèle a de capacité d'apprendre. Néanmoins, ça ne veut pas dire qu'un modèle plus grand sera toujours plus "intelligent".

Par contre, **la taille a une grande influence sur la puissance de calcul nécessaire pour faire fonctionner le modèle et donc sur la consommation énergétique.**

*Graphique - Conseil National du Numérique :  
"20 cartes pour aborder l'impact énergétique de l'IA générative"*





Longueur du texte - facteurs de consommation

# Les "jetons"

La longueur du texte produit par un modèle de langage se quantifie en "jetons" (tokens).

Un jeton constitue une unité de base qui peut englober un ou plusieurs caractères, selon leur fréquence d'apparition ensemble dans la langue.

Par exemple :

**Salut**


1 JETON

**Salut, ça va ?**

5 JETONS

La jetonisation sert à :

- Découper le texte en morceaux que l'IA peut comprendre
- Compter combien de "mots" l'IA peut traiter d'un coup
- Calculer le coût d'utilisation du modèle



Architectures - facteurs de consommation

# Les “mélanges d’experts”

Les modèles “mélanges d’experts” (Mixture of Experts) contiennent plusieurs experts, mais un seul est activé à chaque jeton.

## Avantages

- Moins de puissance de calcul nécessaire
  - DONC consomme moins d’électricité
  - DONC coûte moins cher à utiliser

## Désavantages

- Prend beaucoup de place dans la mémoire de la machine
- Plus complexe à développer
- Peut avoir des problèmes de généralisation

## Exemples



Mistral/**Mistral 8x7B**



DeepSeek/**DeepSeek V3**



Meta/**Llama 4 Scout**

